第五章 神经网络

神经网络发展史

第一阶段

- 1943年, McCulloch和Pitts 提出第一个神经元数学模型, 即M-P模型, 并从原理上证明了人工神经网络能够计算任何算数和逻辑函数
- 1949年, Hebb 发表《The Organization of Behavior》一书, 提出生物神经元学习的机理, 即Hebb学习规则
- 1958年, Rosenblatt 提出感知机网络（Perceptron）模型和其学习规则
- 1960年, Widrow和Hoff提出自适应线性神经元（Adaline）模型和最小均方学习算法
- 1969年, Minsky和Papert 发表《Perceptrons》一书, 指出单层神经网路不能解决非线性问题, 多层网络的训练算法尚无希望. 这个论断导致神经网络进入低谷

神经网络发展史

第二阶段

- 1982年，物理学家Hopfield提出了一种具有联想记忆、优化计算能力的递归网络模型，即Hopfield 网络
- 1986年，Rumelhart 等编辑的著作《Parallel Distributed Proceesing:Explorations in the Microstructures of Cognition》报告了反向传播算法
- 1987年，IEEE 在美国加州圣地亚哥召开第一届神经网络国际会议（ICNN）
- 90年代初，伴随统计学习理论和SVM的兴起，神经网络由于理论不够清楚，试错性强，难以训练，再次进入低谷

神经网络发展史

第三阶段

- 2006年, Hinton提出了深度信念网络(DBN), 通过“预训练+微调”使得深度模型的最优化变得相对容易
- 2012年, Hinton 组参加ImageNet 竞赛, 使用 CNN 模型以超过第二名10个百分点的成绩夺得当年竞赛的冠军（2015年超过人）
- 伴随云计算、大数据时代的到来，计算能力的大幅提升，使得深度学习模型在计算机视觉、自然语言处理、语音识别等众多领域都取得了较大的成功

神经网络发展史

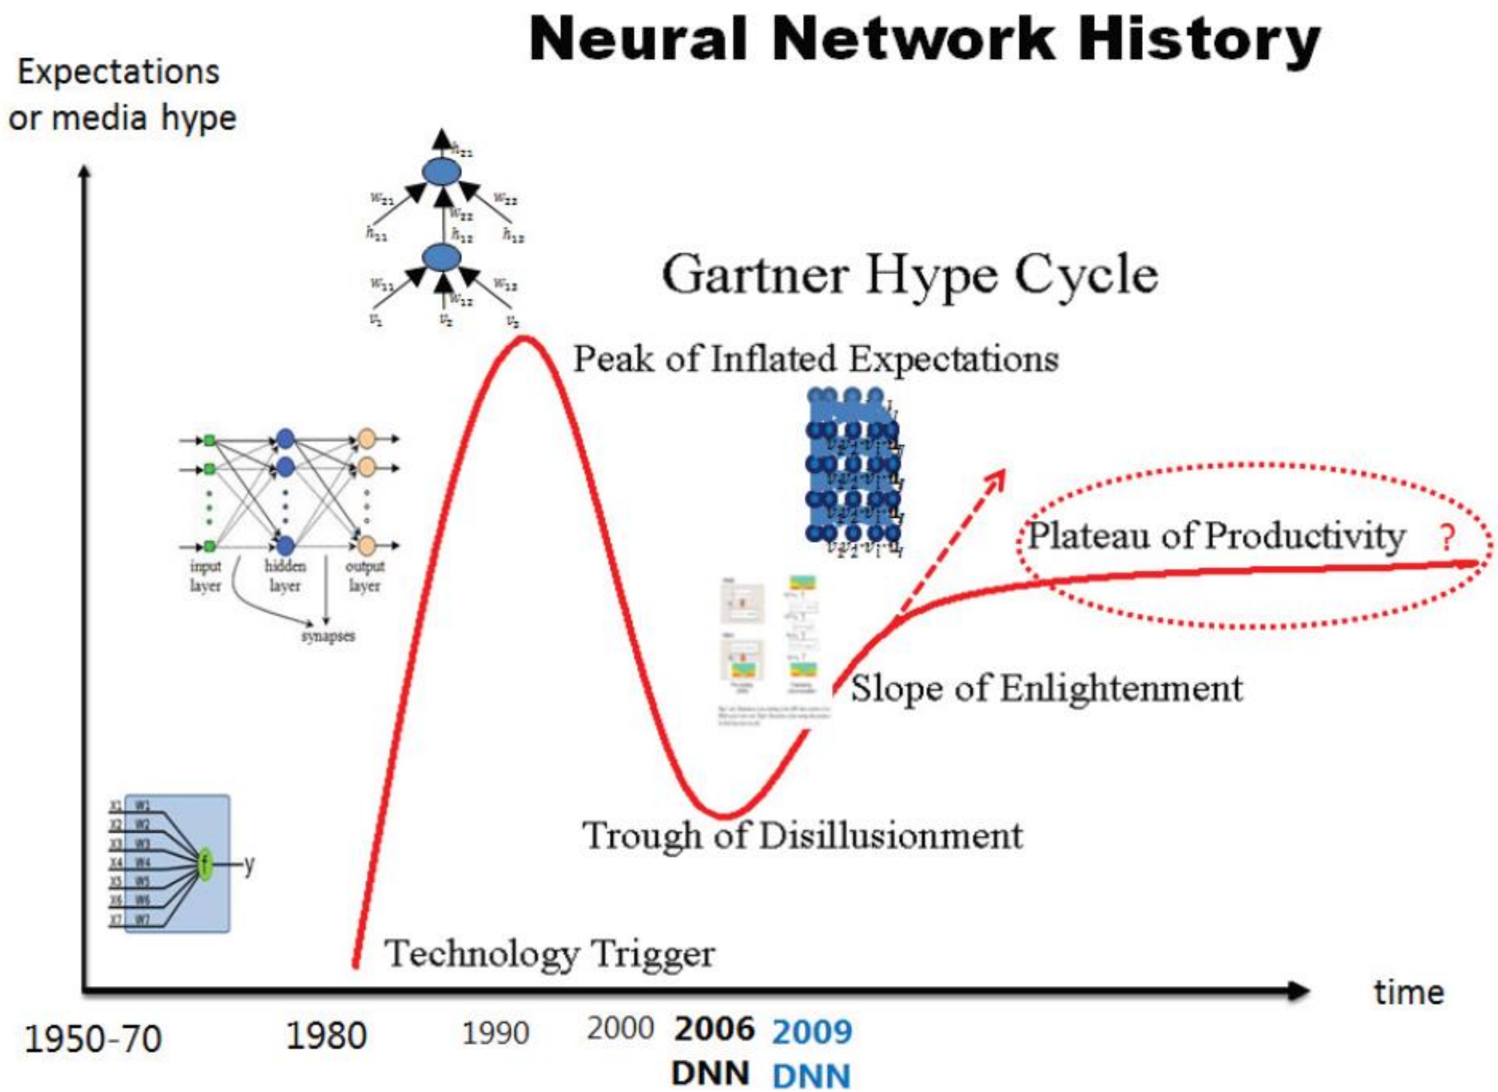

Neural Network History
Expectations
or media hype
Gartner Hype Cycle
Peak of Inflated Expectations
Plateau of Productivity ?
Slope of Enlightenment
Trough of Disillusionment
Technology Trigger
input layer
hidden layer
output layer
synapses
time
1950-70
1980
1990
2000
2006 DNN
2009 DNN

第五章 神经网络

主要内容

- 5.1 神经元模型
- 5.2 感知机与多层网络
- 5.3 误差逆传播算法
- 5.4 全局最小与局部最小
- 5.5 其他常见神经网络
- 5.6 深度学习

第五章 神经网络

主要内容

5.1 神经元模型

□ 神经网络的定义

“神经网络是由具有适应性的简单单元组成的广泛并行互联的网络，它的组织能够模拟生物神经系统对真实世界物体所作出的反应”

[Kohonen, 1988]

- 机器学习中的神经网络通常是指“神经网络学习”或者机器学习与神经网络两个学科的交叉部分
- 神经元模型即上述定义中的“简单单元”是神经网络的基本成分
- 生物神经网络：每个神经元与其他神经元相连，当它“兴奋”时，就会向相连的神经云发送化学物质，从而改变这些神经元内的电位；如果某神经元的电位超过一个“阈值”，那么它就会被激活，即“兴奋”起来，向其它神经元发送化学物质

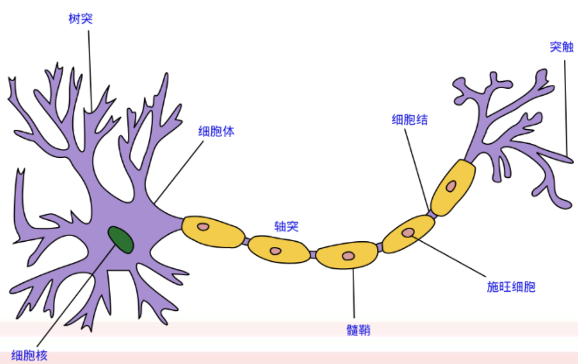

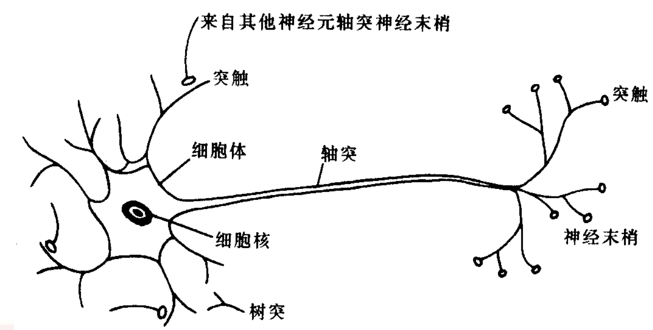

5.1 神经元模型

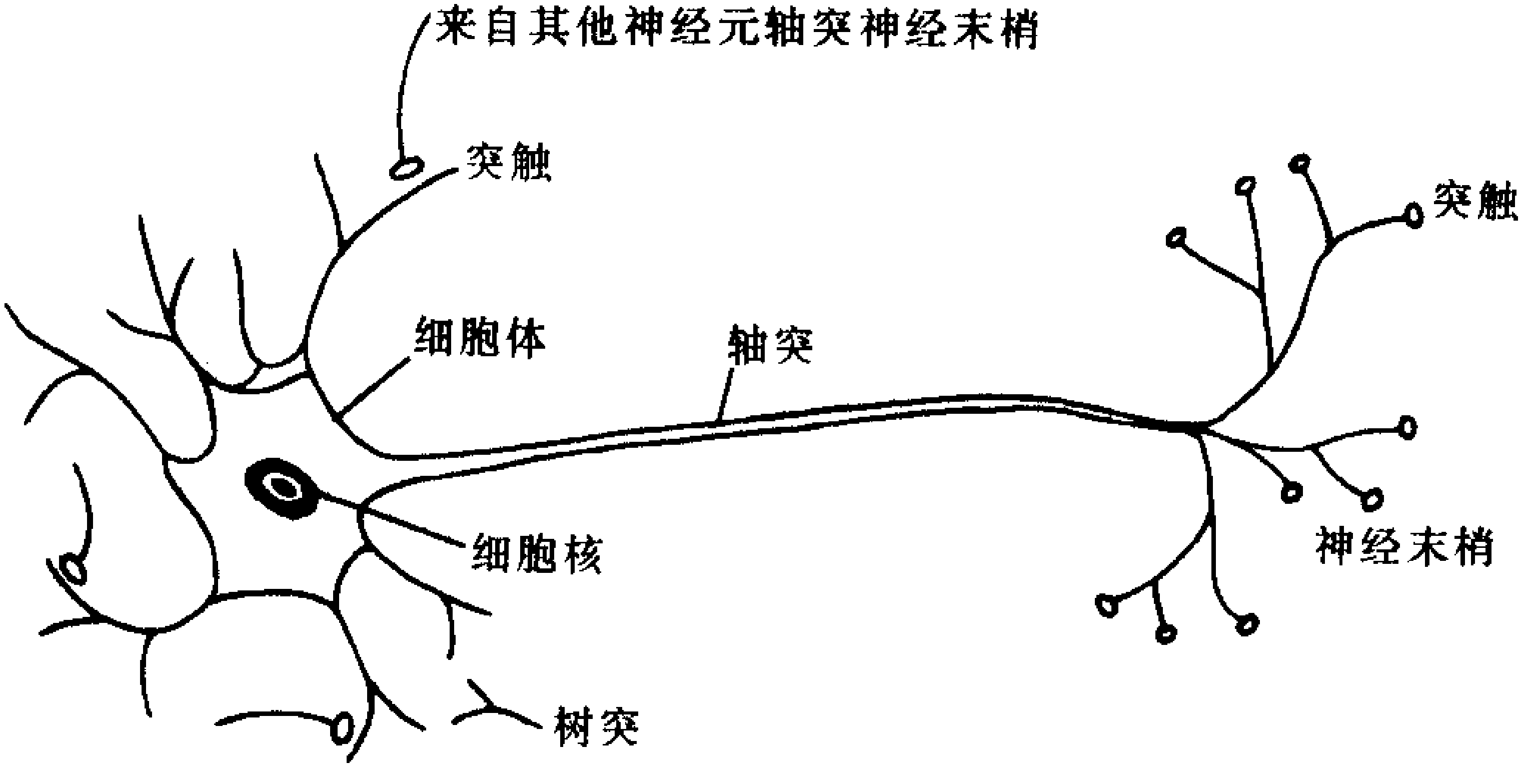

5.1 神经元模型

M-P 神经元模型 [McCulloch and Pitts, 1943]

- 输入：来自其他n个神经云传递过来的输入信号
- 处理：输入信号通过带权重的连接进行传递，神经元接受到总输入值将与神经元的阈值进行比较
- 输出：通过激活函数的处理以得到输出

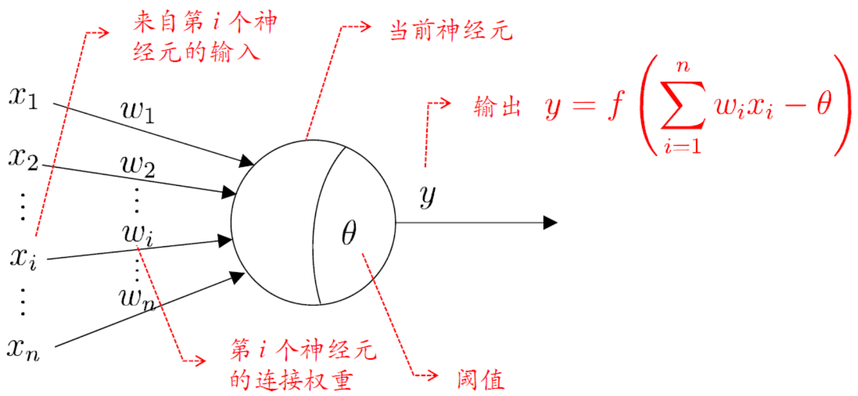

图 5.1 M-P 神经元模型

5.1 神经元模型

激活函数

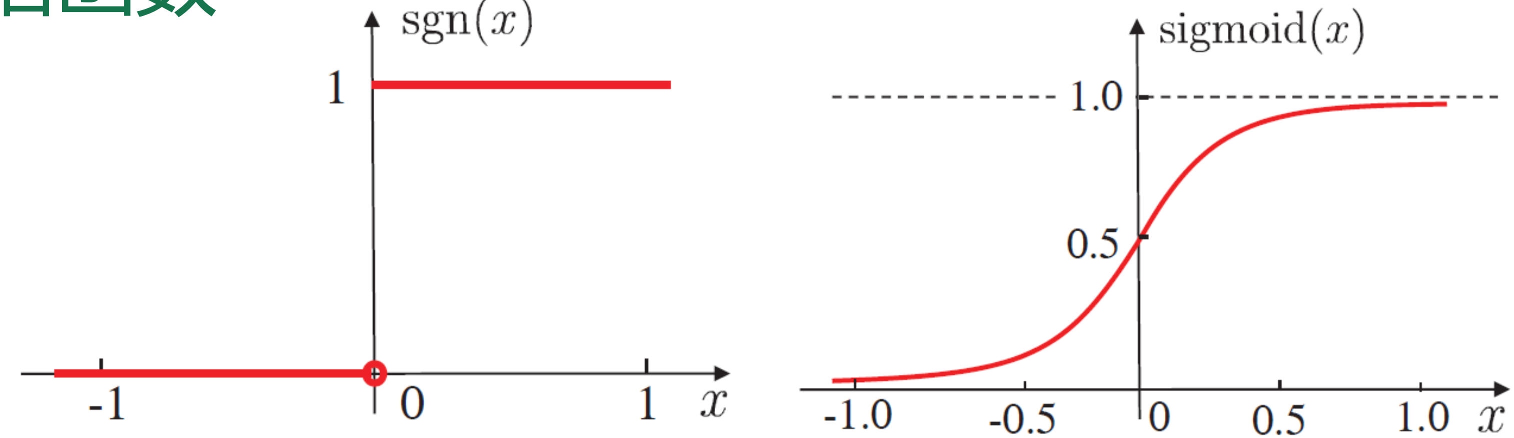

$$\operatorname{sgn}(x) = \begin{cases} 1, & \text{if } x \geq 0; \\ 0, & \text{if } x < 0. \end{cases}$$

$$\operatorname{sigmoid}(x) = \frac{1}{1+e^{-x}}$$

(a) 阶跃函数　　(b) Sigmoid 函数

图 5.2　典型的神经元激活函数

- 理想激活函数是阶跃函数，0表示抑制神经元而1表示激活神经元
- 阶跃函数具有不连续、不光滑等不好的性质，常用的是 Sigmoid 函数

第五章 神经网络

主要内容

- 5.1 神经元模型
- 5.2 感知机与多层网络
- 5.3 误差逆传播算法
- 5.4 全局最小与局部最小
- 5.5 其他常见神经网络
- 5.6 深度学习

5.2 感知机与多层网络

感知机

- 感知机由两层神经元组成，输入层接受外界输入信号传递给输出层，输出层是M-P神经元（阈值逻辑单元）
- 感知机能够容易地实现逻辑与、或、非运算
  - “与” $x_1 \wedge x_2$：令 $w_1 = w_2 = 1, \theta = 0$，则 $y = f(1 \cdot x_1 + 1 \cdot x_2 - 2)$，仅在$x_1 = x_2 = 1$ 时，$y = 1$.
  - “或”$x_1 \vee x_2$：令 $w_1 = w_2 = 1, \theta = 0.5$，则 $y = f(1 \cdot x_1 + 1 \cdot x_2 - 2)$，仅在 $x_1 = 1$或者 $x_2 = 1$ 时，$y = 1$.
  - “非” $\neg x_1$：令$w_1 = -0.6, w_2 = 0, \theta = -0.5$，则 当 $x_1 = 1$时，$y = 0$；当 $x_1 = 0$，$y = 1$.

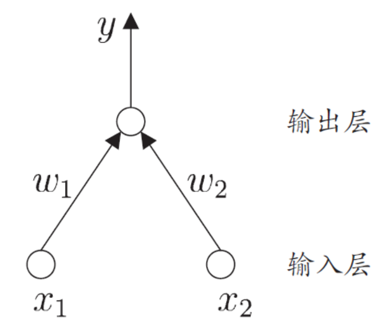

图 5.3 两个输入神经元的感知机网络结构示意图

5.2 感知机与多层网络

感知机学习

- 给定训练数据集，权重 $w_i(i=1,2,\cdots,n)$ 与阈值 θ 可以通过学习得到

- 感知机学习规则

对训练样例 $(\boldsymbol{x},y)$ 若当前感知机的输出为 $\hat{y}$，则感知机权重调整规则为：

$$w_i \leftarrow w_i + \triangle w_i$$
$$\triangle w_i = \eta(y-\hat{y})x_i$$

其中 $\eta \in (0,1)$称为学习率

若感知机对训练样例$(\boldsymbol{x},y)$预测正确，则感知机不发生变化；否则根据错误程度进行权重的调整.

5.2 感知机与多层网络

感知机求解与、或、非问题

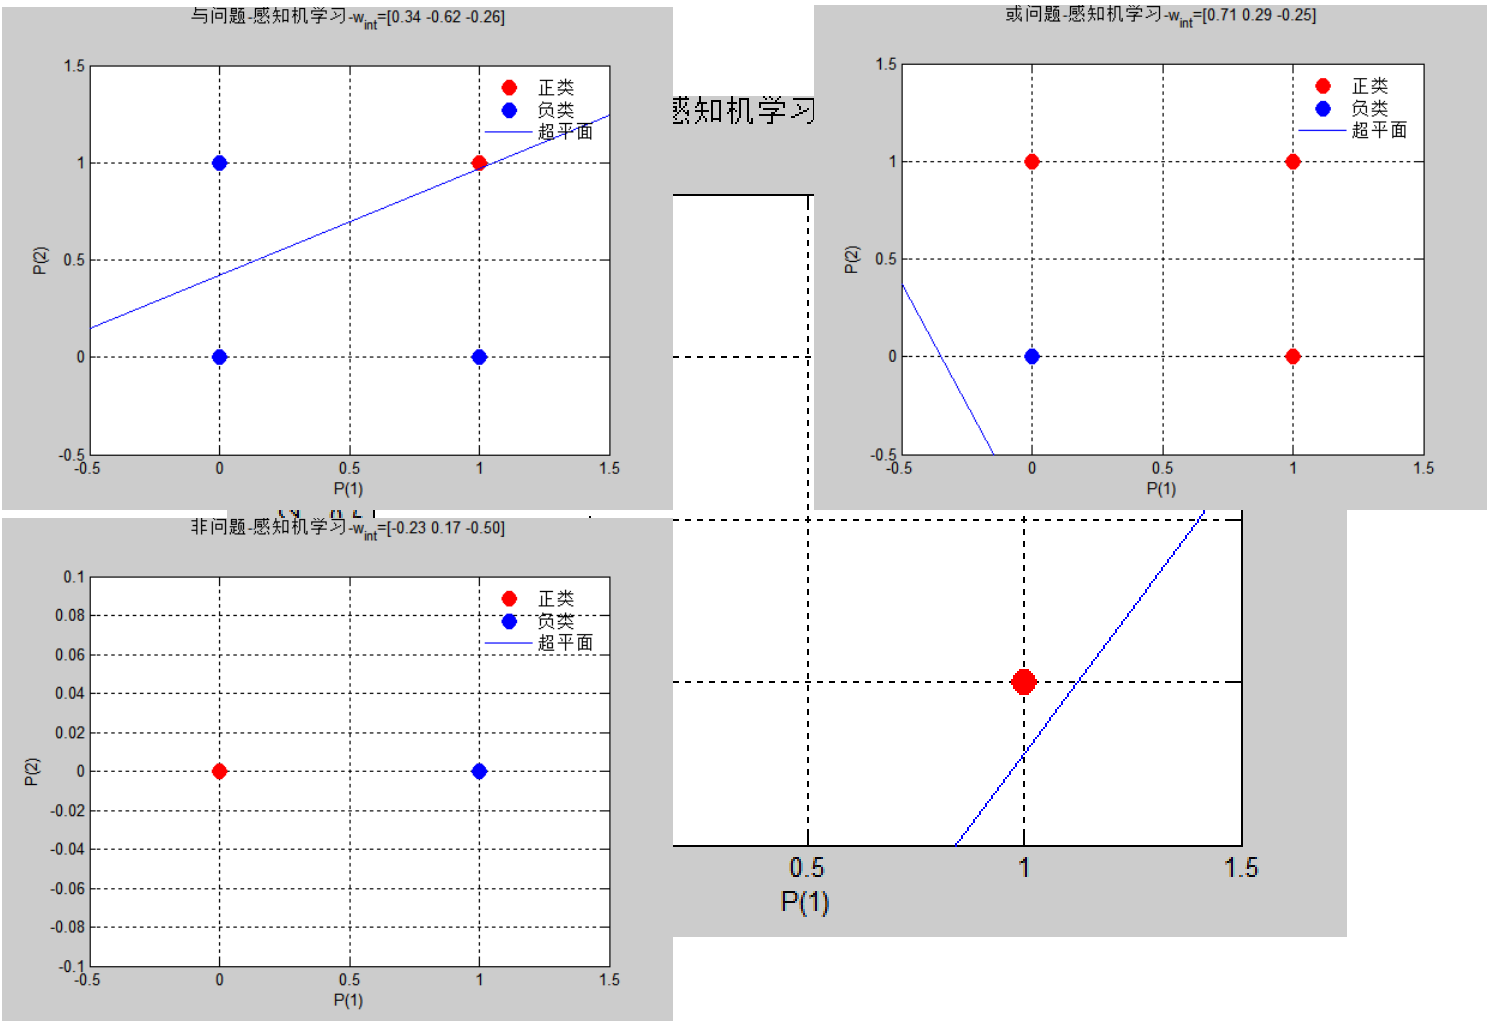

5.2 感知机与多层网络

感知机求解异、或、非、异或问题

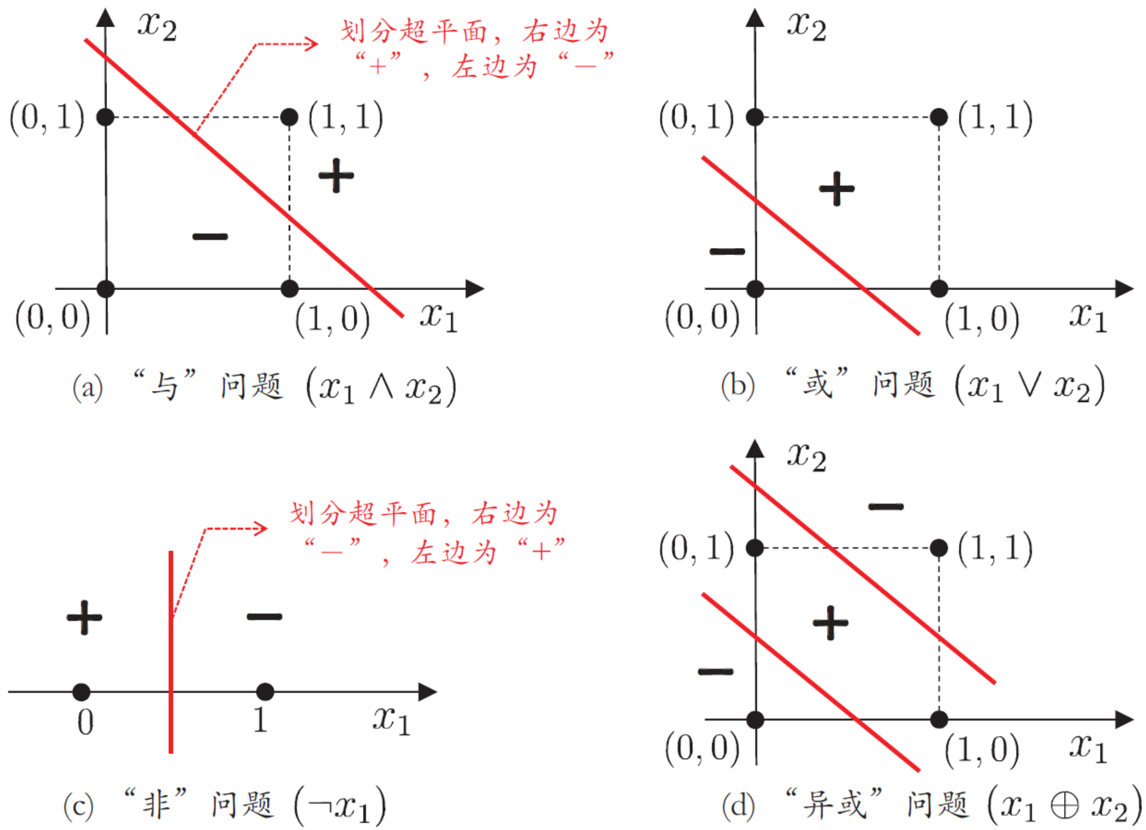

图 5.4 线性可分的“与”“或”“非”问题与非线性可分的“异或”问题

5.2 感知机与多层网络

感知机学习能力

- 若两类模式线性可分，则感知机的学习过程一定会收敛；否感知机的学习过程将会发生震荡

[Minsky and Papert, 1969]

- 单层感知机的学习能力非常有限，只能解决线性可分问题
  - 事实上，与、或、非问题是线性可分的，因此感知机学习过程能够求得适当的权值向量．而异或问题不是线性可分的，感知机学习不能求得合适解
  - 对于非线性可分问题，如何求解？

    多层感知机

5.2 感知机与多层网络

多层感知机

- 解决异或问题的两层感知机

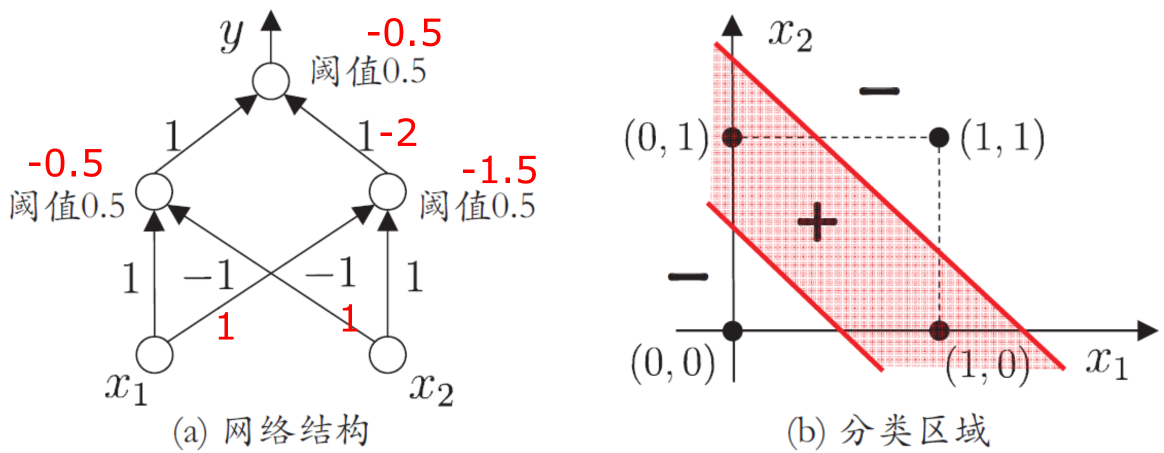

图 5.5　能解决异或问题的两层感知机

- 输出层与输入层之间的一层神经元，被称之为隐层或隐含层，隐含层和输出层神经元都是具有激活函数的功能神经元

5.2 感知机与多层网络

多层感知机

- 解决异或问题的两层感知机

$$\underline{x} \rightarrow \underline{y} = [y_1, y_2]^T$$

1st phase				2nd phase
x_1	x_2	y_1	y_2	
0	0	0(-)	0(-)	B(0)
0	1	1(+)	0(-)	A(1)
1	0	1(+)	0(-)	A(1)
1	1	1(+)	1(+)	B(0)

$$g_1(\underline{x}) = x_1 + x_2 - \frac{1}{2} = 0$$

$$g_2(\underline{x}) = x_1 + x_2 - \frac{3}{2} = 0$$

$$g(\underline{y}) = y_1 - 2y_2 - \frac{1}{2} = 0$$

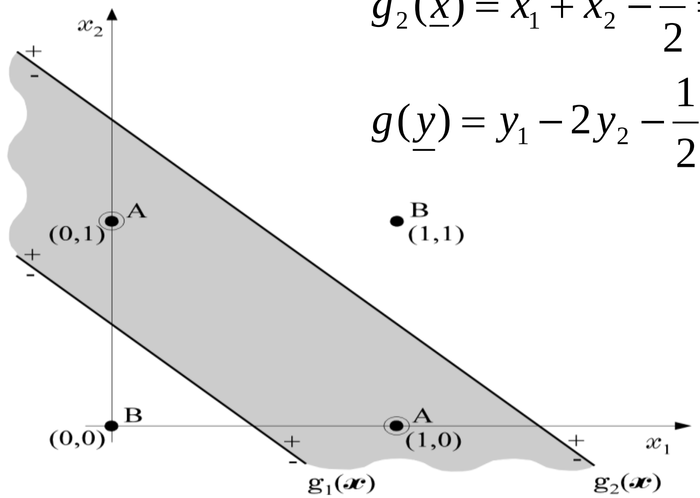

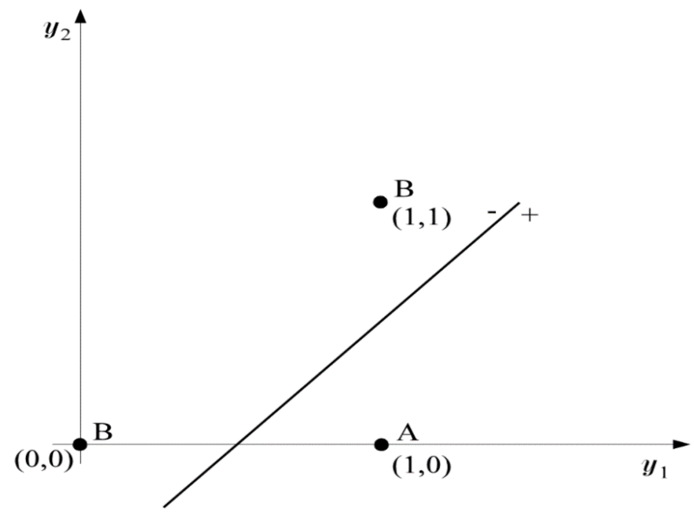

5.2 感知机与多层网络

多层前馈神经网络

- 定义：每层神经元与下一层神经元全互联，神经元之间不存在同层连接也不存在跨层连接
- 前馈：输入层接受外界输入，隐含层与输出层神经元对信号进行加工，最终结果由输出层神经元输出
- 学习：根据训练数据来调整神经元之间的 “连接权” 以及每个功能神经元的 “阈值”
- 多层网络：包含隐层的网络

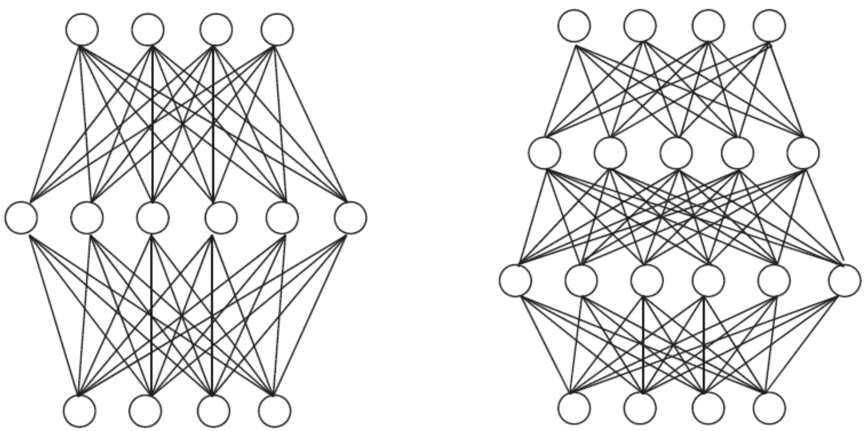

(a) 单隐层前馈网络　　(b) 双隐层前馈网络

第五章 神经网络

主要内容

5.3 误差逆传播算法

误差逆传播算法（Error BackPropagation，简称BP）是最成功的训练多层前馈神经网络的学习算法.

- 给定训练集 $D=\{(\boldsymbol{x}_i, y_i)\}, \boldsymbol{x}_i \in R^d, y_i \in R^l, (i=1,2,\cdots,m)$，即输入示例由$d$个属性描述，输出 l 维实值向量.
- 为方便讨论，给定一个拥有 d个输入神经元，l个输出神经元,q个隐层神经元的多层前向前馈网络结构.
- 记号：

θ_j：输出层第j个神经元阈值；

γ_h：隐含层第h个神经元阈值；

v_{ih}：输入层与隐层神经元之间的连接权重；

w_{hj}：隐层与输出层神经元之间的连接权重；

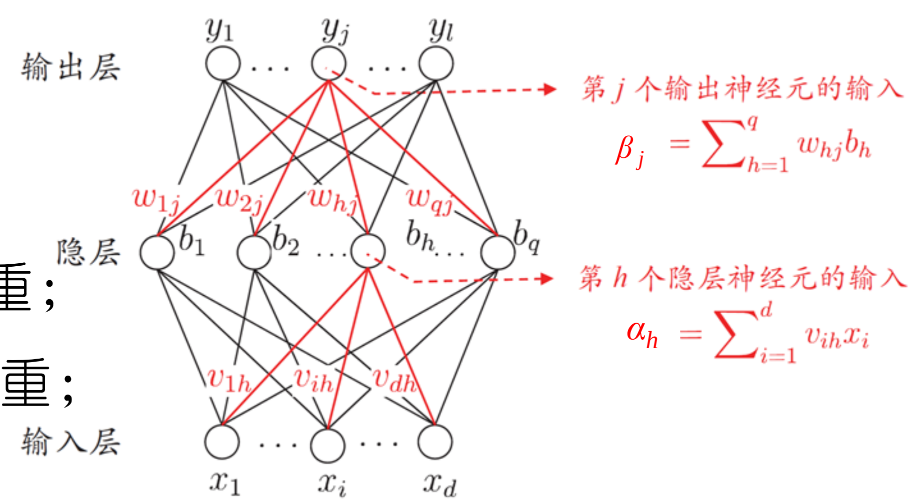

5.3 误差逆传播算法

对于样例 $(\boldsymbol{x}_k, \boldsymbol{y}_k)$，假设网络的实际输出为 $\hat{\boldsymbol{y}}_k$

- 前向计算

step1: $b_h = f(\beta_h - \gamma_h), \beta_h = \sum_{i=1}^{d} v_{ih} x_i$

step2: $\hat{y}_j^k = f(\alpha_j - \theta_j), \alpha_h = \sum_{i=1}^{q} w_{hj} b_h \quad (5.3)$

step3: $E_k = \frac{1}{2} \sum_{j=1}^{l} (\hat{y}_j^k - y_j^k)^2$

- 参数数目

权重: v_{ih}, w_{hj} 阈值: θ_j, γ_h $(i = 1, \cdots, d, h = 1, , \cdots, q, j = 1, \cdots, l)$

因此网络中需要 $(d + l + 1)q + l$ 个参数需要优化

- 参数优化

BP是一个迭代学习算法，在迭代的每一轮中采用广义的感知机学习规则对参数进行更新估计，任意的参数 v 的更新估计式为

$$v \leftarrow v + \triangle v.$$

5.3 误差逆传播算法

BP 学习算法

- BP算法基于梯度下降策略，以目标的负梯度方向对参数进行调整. 对误差 E_k ，给定学习率 η

$$\triangle w_{hj} = -\eta \frac{\partial E_k}{\partial w_{jk}}$$

$$\frac{\partial E_k}{\partial w_{hj}} = \frac{\partial E_k}{\partial \hat{y}_j^k} \cdot \frac{\partial \hat{y}_j^k}{\partial \beta_j} \cdot \frac{\partial \beta_j}{\partial_{hj}}$$

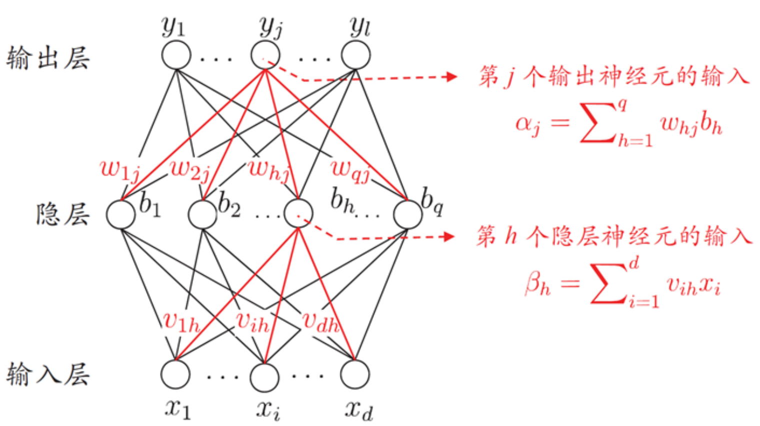

$$\begin{aligned} g_j &= -\frac{\partial E_k}{\partial \hat{y}_j^k} \cdot \frac{\partial \hat{y}_j^k}{\partial \beta_j} \\ &= -(\hat{y}_j^k - y_j^k) f'(\beta_j - \theta_j) \\ &= \hat{y}_j^k (1 - \hat{y}_j^k)(y_j^k - \hat{y}_j^k) \quad (5.10) \end{aligned}$$

$$\triangle w_{hj} = \eta b_j g_h \quad (5.11)$$

5.3 误差逆传播算法

BP 学习算法

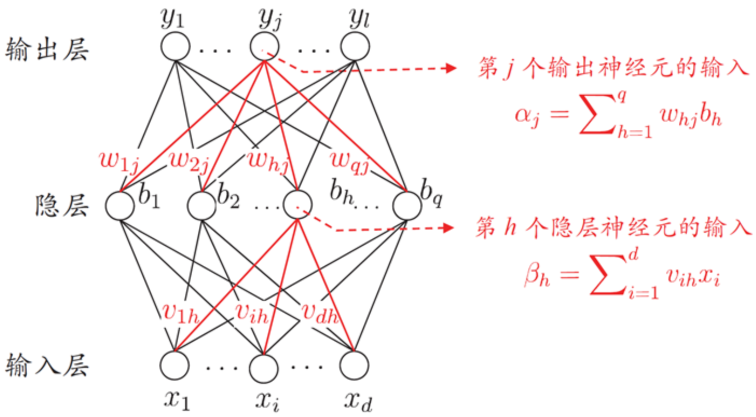

- 类似的可以推导出：

$$\Delta\theta_j = -\eta g_j, \qquad (5.12)$$

$$\Delta v_{ih} = \eta e_h x_i, \qquad (5.13)$$

$$\Delta\gamma_h = -\eta e_h, \qquad (5.14)$$

其中

$$e_h = -\frac{\partial E_k}{\partial b_h} \cdot \frac{\partial b_h}{\partial \alpha_h}$$

$$= -\sum_{j=1}^{l} \frac{\partial E_k}{\partial \beta_j} \partial b_h f'(\alpha_h - \gamma_h)$$

$$= \sum_{j=1}^{h} w_{hj} g_j f'(\alpha_h - \gamma_h)$$

$$= b_h(1 - b_h) \sum_{j=1}^{h} w_{hj} g_j. \qquad (5.15)$$

- 学习率 $\eta \in (0, 1)$ 控制着算法每一轮迭代中的更新步长，若太长则让容易震荡，太小则收敛速度又会过慢.

5.3 误差逆传播算法

BP 学习算法

输入: 训练集 $D = \{(\boldsymbol{x}_k, \boldsymbol{y}_k)\}_{k=1}^{m}$;
学习率 η.

过程:

1: 在(0, 1)范围内随机初始化网络中所有连接权和阈值
2: **repeat**
3: **for all** $(\boldsymbol{x}_k, \boldsymbol{y}_k) \in D$ **do**
4: 根据当前参数和式(5.3) 计算当前样本的输出 $\hat{\boldsymbol{y}}_k$;
5: 根据式(5.10) 计算输出层神经元的梯度项 g_j;
6: 根据式(5.15) 计算隐层神经元的梯度项 e_h;
7: 根据式(5.11)-(5.14) 更新连接权 w_{hj}, v_{ih} 与阈值 θ_j, γ_h
8: **end for**
9: **until** 达到停止条件

输出: 连接权与阈值确定的多层前馈神经网络

图 5.8 误差逆传播算法

5.3 误差逆传播算法

BP 算法实验

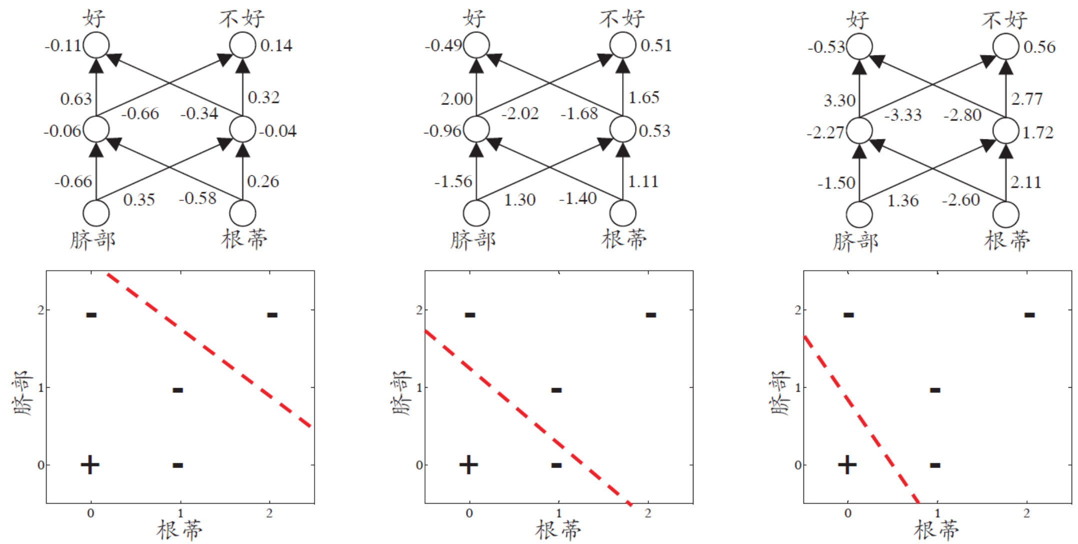

(a) 第 25 轮　(b) 第 50 轮　(c) 第 100 轮

图 5.9　在 2 个属性、5 个样本的西瓜数据上，BP网络参数更新和分类边界的变化情况

5.3 误差逆传播算法

□ 标准 BP 算法

- 每次针对单个训练样例更新权值与阈值.
- 参数更新频繁, 不同样例可能抵消, 需要多次迭代.

□ 累计 BP 算法

- 其优化的目标是最小化整个训练集上的累计误差

$$E = \frac{1}{m} \sum_{k=1}^{m} E_k$$

- 读取整个训练集一遍才对参数进行更新, 参数更新频率较低.

□ 实际应用

但在很多任务中, 累计误差下降到一定程度后, 进一步下降会非常缓慢, 这时标准BP算法往往会获得较好的解, 尤其当训练集非常大时效果更明显.

5.3 误差逆传播算法

◻ 多层前馈网络表示能力

只需要一个包含足够多神经元的隐层，多层前馈神经网络就能以任意精度逼近任意复杂度的连续函数

[Hornik et al.， 1989]

◻ 多层前馈网络局限

- 神经网络由于强大的表示能力，经常遭遇过拟合．表现为：训练误差持续降低，但测试误差却可能上升
- 如何设置隐层神经元的个数仍然是个未决问题．实际应用中通常使用“试错法”调整

◻ 缓解过拟合的策略

- 早停：在训练过程中，若训练误差降低，但验证误差升高，则停止训练
- 正则化：在误差目标函数中增加一项描述网络复杂程度的部分，例如连接权值与阈值的平方和

第五章 神经网络

主要内容

- 5.1 神经元模型
- 5.2 感知机与多层网络
- 5.3 误差逆传播算法
- 5.4 全局最小与局部最小
- 5.5 其他常见神经网络
- 5.6 深度学习

5.4 全局最小与局部极小

- 对 $\boldsymbol{w}^*$ 和 θ^*，若存在 $\epsilon > 0$使得

$$\forall(\boldsymbol{w};\theta) \in \{\|(\boldsymbol{w};\theta) - (\boldsymbol{w}^*;\theta^*)\| \leq \epsilon\},$$

都有 $E(\boldsymbol{w};\theta) \geq E(\boldsymbol{w}^*;\theta^*)$成立, 则 $(\boldsymbol{w}^*;\theta^*)$ 为局部极小解；若度参数空间中任意的 $(\boldsymbol{w};\theta)$, 都有 $E(\boldsymbol{w};\theta) \geq E(\boldsymbol{w}^*;\theta^*)$, 则 $(\boldsymbol{w}^*;\theta^*)$ 为全局最小解. 两者对应的 $E(\boldsymbol{w}^*;\theta^*)$分别称为误差函数的局部最小解和全局最小值.

- 显然参数空间梯度为零的点, 只要其误差函数值小于邻点的误差函数值, 就是局部极小点
- 可能存在多个局部极小值, 但却只会有一个全局极最小值

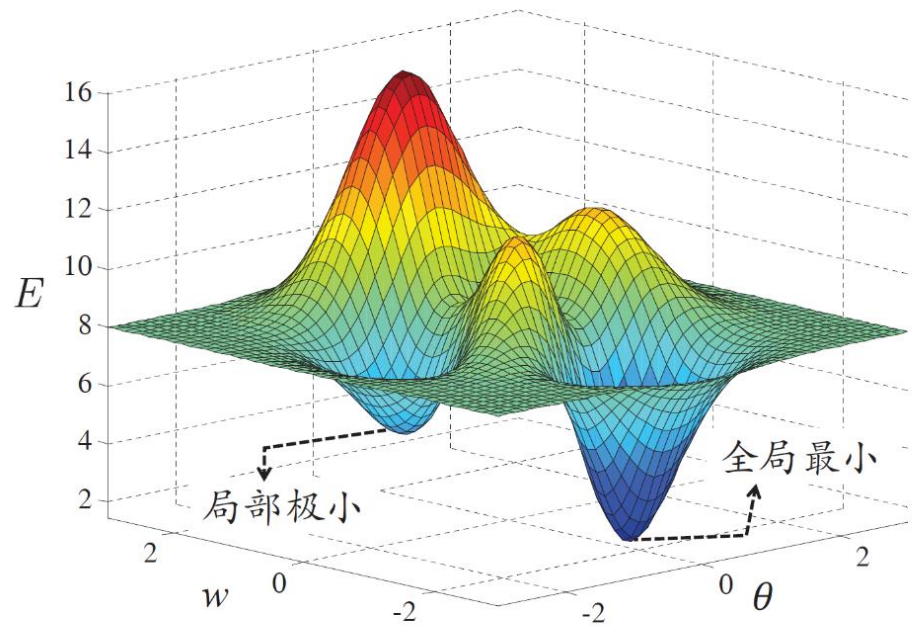

5.4 全局最小与局部极小

"跳出"局部最小的策略

基于梯度的搜索是使用最为广泛的参数寻优方法．如果误差函数仅有一个局部极小，那么此时找到的局部极小就是全局最小；然而, 如果误差函数具有多个局部极小，则不能保证找到的解是全局最小．在现实任务中，通常采用以下策略"跳出"局部极小，从而进一步达到全局最小．

- 多组不同的初始参数优化神经网络，选取误差最小的解作为最终参数.
- 模拟退火技术 [Aarts and Korst，1989]．每一步都以一定的概率接受比当前解更差的结果, 从而有助于跳出局部极小.
- 随机梯度下降．与标准梯度下降法精确计算梯度不同, 随机梯度下降法在计算梯度时加入了随机因素.
- 遗传算法 [Goldberg，1989]. 遗传算法也常用来训练神经网络以更好地逼近全局极小.

第五章 神经网络

主要内容

- 5.1 神经元模型
- 5.2 感知机与多层网络
- 5.3 误差逆传播算法
- 5.4 全局最小与局部最小
- 5.5 其他常见神经网络
- 5.6 深度学习

5.5 其他常见神经网络

RBF 网络 [Broomhead and Lowe, 1988]

- RBF 网络是一种单隐层前馈神经网络，它使用径向基函数作为隐层神经元激活函数，而输出层则是隐层神经元输出的线性组合.

- RBF网络模型

假定输入为d 维的向量$\boldsymbol{x}$，输出为实值，则RBF 网络可以表示为

$$\varphi(\boldsymbol{x}) = \sum_{i=1}^{q} w_i \rho(\boldsymbol{x}, \boldsymbol{c}_i)$$

其中q为隐层神经元的个数，$\boldsymbol{c}_i$和 w_i分别是第 i神经元对应的中心和权重，$\rho(\boldsymbol{x}, \boldsymbol{c}_i)$是径向基函数.

常用的高斯径向基函数形如

$$\rho(\boldsymbol{x}, \boldsymbol{c}_i) = e^{-\beta_i \|\boldsymbol{x}-\boldsymbol{c}_i\|^2}$$

5.5 其他常见神经网络

RBF 网络

□ RBF网络性质

具有足够多隐层神经元RBF 神经网络能以任意精度逼近任意连续函数.

[Park and Sandberg，1991]

□ RBF网络训练

- Step1:确定神经元中心，常用的方式包括随机采样、聚类等
- Step2:利用BP算法等确定参数

5.5 其他常见神经网络

ART 网络

◻ 竞争学习

竞争学习是神经网络中一种常用的无监督学习策略，在使用该策略时，网络的输出神经元相互竞争，每一时刻仅有一个神经元被激活，其他神经元的状态被抑制.

◻ ART 网络 [Carpenter and Grossberg, 1987]

- ART 网络是竞争学习的重要代表
- ART 网络由比较层、识别层、识别阈值和重置模块构成
- 比较层负责接收输入样本，并将其传送给识别层神经元
- 识别层每个神经元对应一个模式类，神经元的数目可在训练过程中动态增长以增加新的模式类

5.5 其他常见神经网络

ART 网络

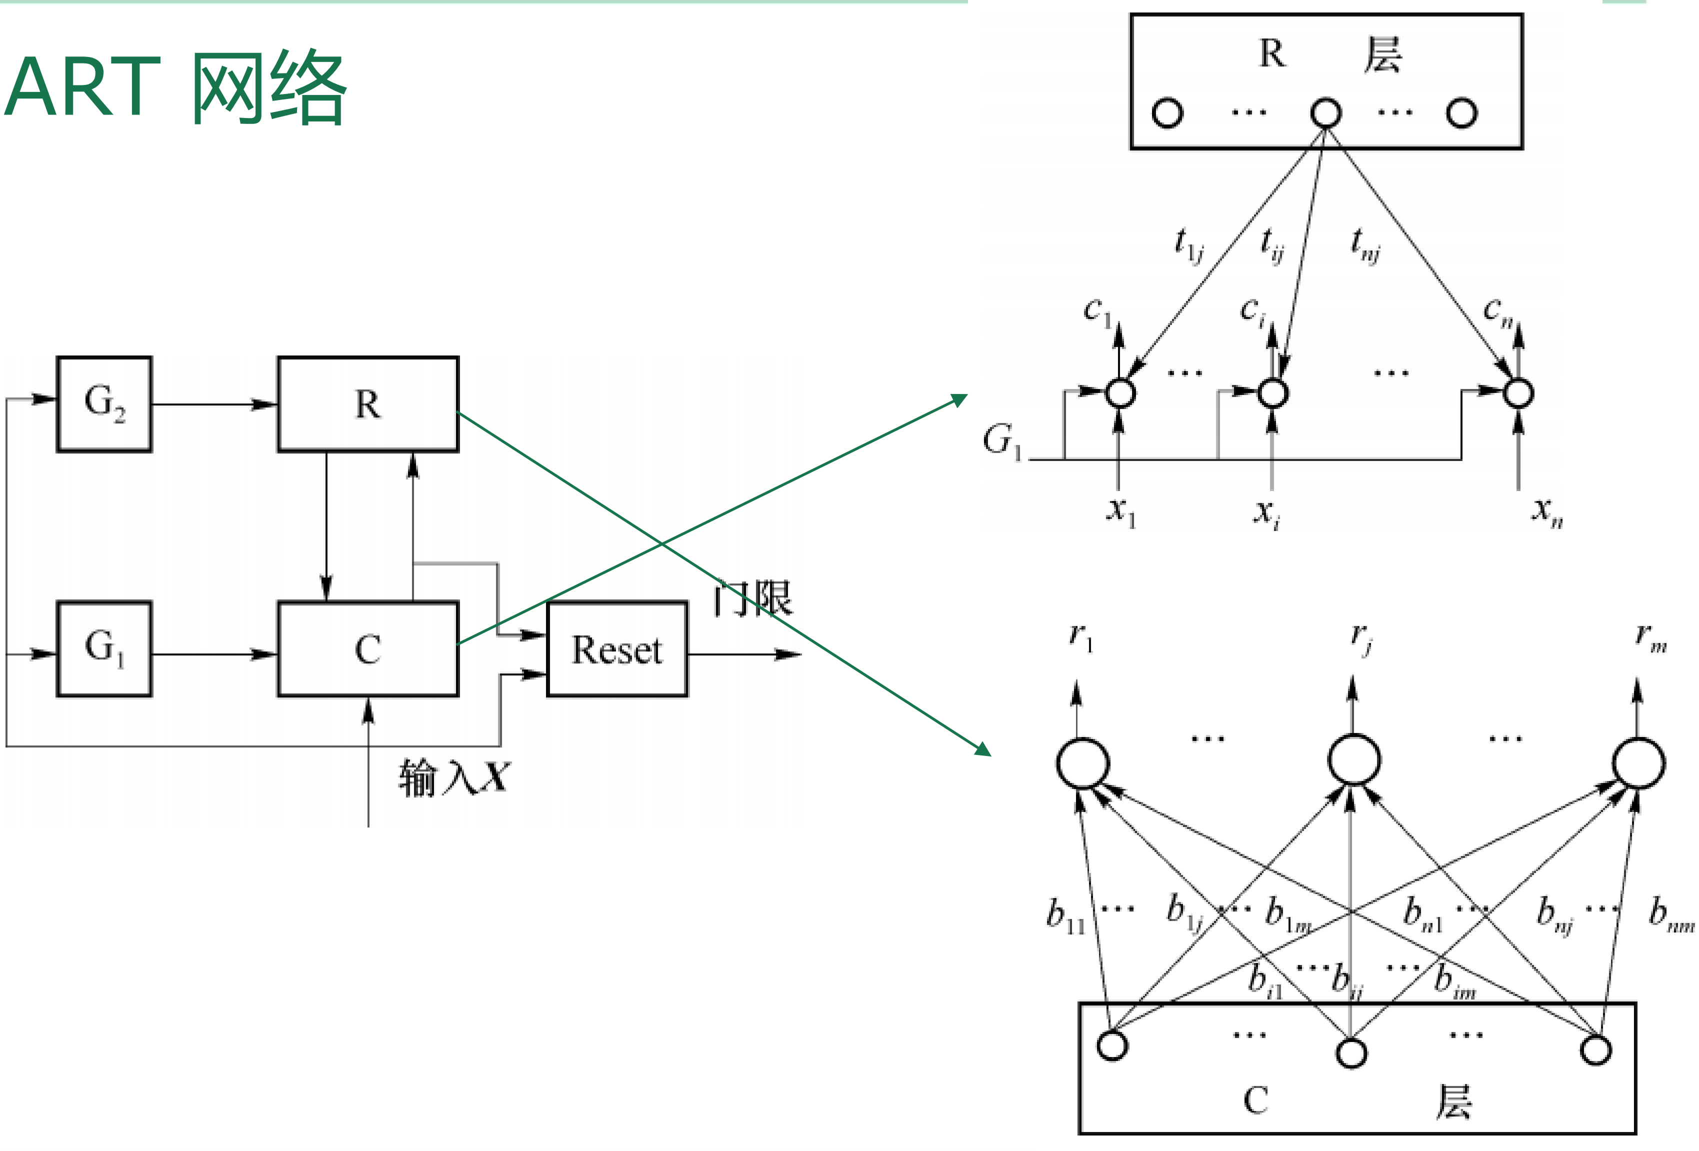

5.5 其他常见神经网络

ART 网络

ART 网络性能依赖于识别阈值

- 识别阈值高时，输入样本将会分成比较多、得到较精细分类
- 识别阈值低时，输入样本将会分成比较少、产生较粗略分类

ART 网络的优势

- ART较好的解决了竞争学习中的“可塑性-稳定性窘境”，可塑性是指神经网络要有学习新知识的能力；稳定性是指神经网络在学习新知识时要保持对旧知识的记忆.
- ART 网络可以增量学习或在线学习

ART 网络的发展

ART2 网络、FuzzyART 网络、ARTMAP 网络

5.5 其他常见神经网络

SOM 网络 [Kohonen, 1982]

- SOM 网络是一种竞争型的无监督神经网络, 它能将高维数据映射到低维空间（通常为2维）, 同时保持输入数据在高维空间的拓扑结构, 即将高维空间中相似的样本点映射到网络输出层中邻近神经元.
- 如图, SOM 网络中的输出层神经元以矩阵方式排列在二维空间中, 每个神经元都拥有一个权值向量, 网络在接收输入向量后, 将会确定输出层获胜神经元, 它决定了该输入向量在低维空间中的位置.

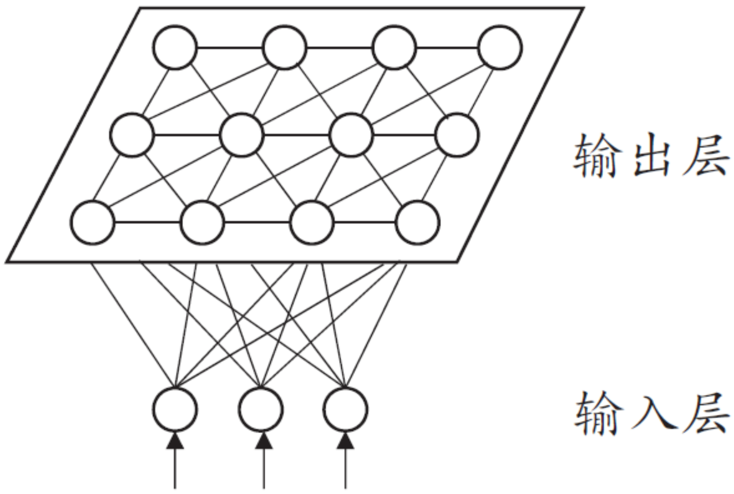

图 5.11 SOM 网络结构

5.5 其他常见神经网络

SOM 网络 [Kohonen, 1982]

SOM 网络训练

Step1:接受到一个训练样本后，每个输出层神经元计算该样本与自身携带的权向量之间的距离，距离最近的神经元成为竞争获胜者

Step2:最佳匹配单元及其近邻神经元的权值将被调整，使得这些权向量与当前输入样本的距离缩小

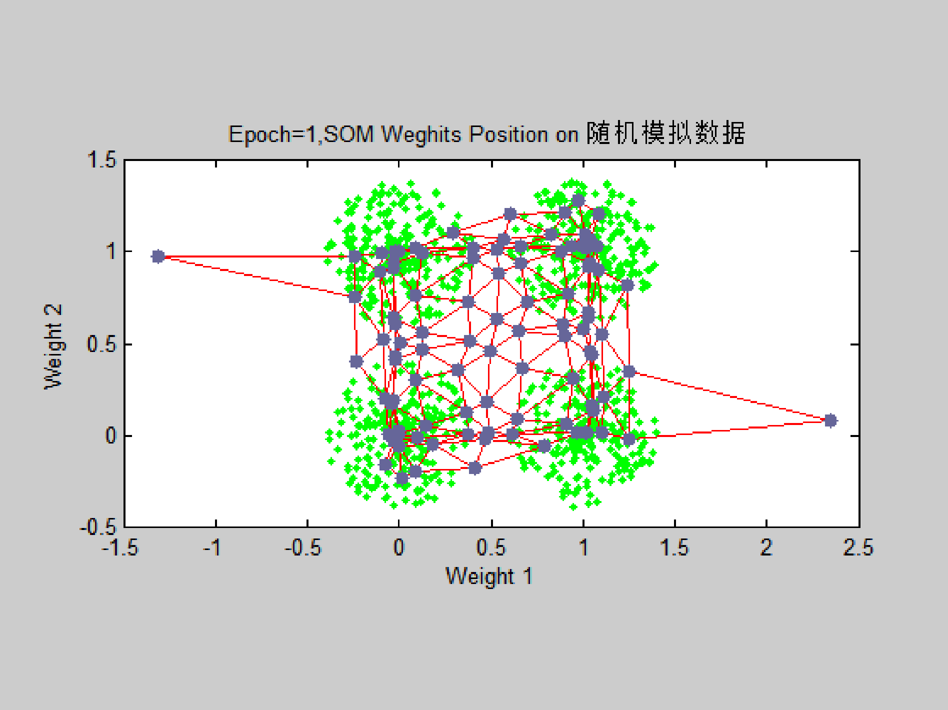

5.5 其他常见神经网络

级联相关网络 [Fahlman and Lebiere 1990]

级联相关网络不仅利用训练样本优化连接权值，阈值参数，将网络的结构也当做学习的目标之一，希望在训练过程中找到适合数据的网络结构.

级联与相关

级联：建立层次连接的层级结构

相关：最大化神经元的输出与网络误差时间的相关性来训练相关参数

网络优化演示

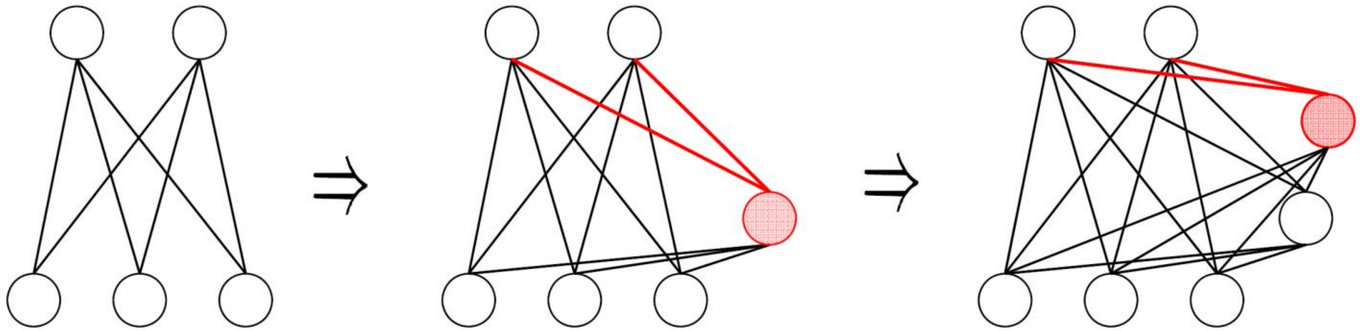

(a) 初始状态　(b) 增加一个隐层结点　(c) 增加第二个隐层结点

5.5 其他常见神经网络

Elman 网络 [Elman 1990]

递归神经网络

- 允许网络中出现环形结构，使得神经元的输出反馈回来作为输入信号
- *t* 时刻网络的输出状态：由 *t* 时刻的输入状态和 *t*-1 时刻的网络状态决定

Elman 网络

Elamn 网络是最常用的递归神经网络之一，结构如图所示，这种结构与前馈神经网络很相似，但是隐层神经元的输出被反馈回来，与下一时刻输入层神经元提供的信号一起，作为隐层神经元在下一时刻的输入

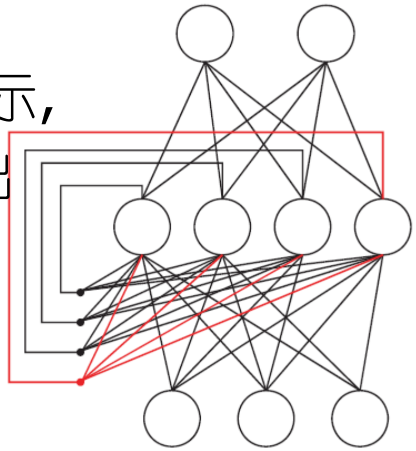

图 5.13 Elman 网络结构

训练算法

推广的BP算法. [Pineda, 1987]

5.5 其他常见神经网络

Boltzmann 机

□ 能量模型

神经网络中有一类模型为网络定义一个“能量”，能量最小化时网络达到理想状态，而网络的训练就是在最小化这个能量函数.

□ Boltzmann 机

- Boltzmann 机就是一种基于能量的模型
- 结构：显层与隐层

  显层：数据的输入输出

  隐层：数据的内在表达
- 神经元

  布尔型，即只能取0和1 两种状态，

  其中1 表示激活，0表示抑制.

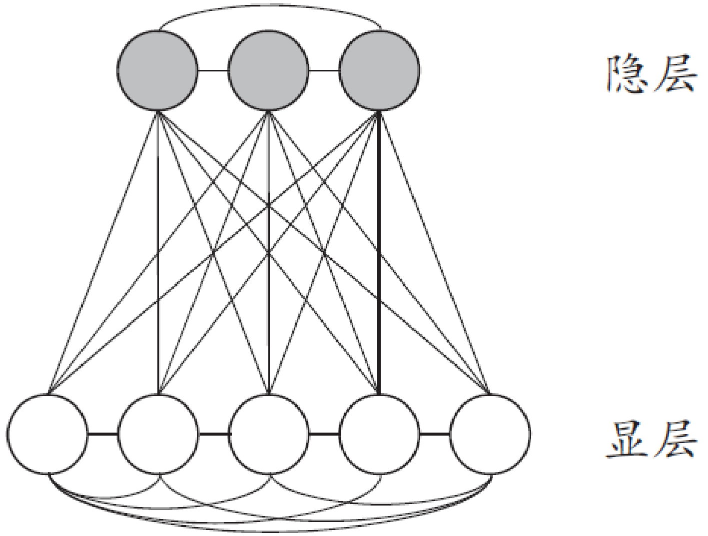

(a) Boltzmann机

5.5 其他常见神经网络

Boltzmann 机 [Ackley et al. , 1985]

Boltzmann 机能量

令状态向量$\boldsymbol{s} \in \{0,1\}^n$，则其对应的Boltzmann 机能量定义为

$$E(\boldsymbol{s}) = -\sum_{i=1}^{n-1}\sum_{j=i+1}^{n} w_{ij}s_is_j - \sum_{i=1}^{n}\theta_i s_i$$

其中w_{ij}表示两个神经元之间的连接权值，θ_i表示神经元的阈值.

Boltzmann 分布

网络中的神经元以任意不依赖与输入值得顺序进行更新，则网络最终将达到Boltzmann 分布，此时状态$P(\boldsymbol{s}) = \frac{e^{-E(\boldsymbol{s})}}{\sum_t e^{-E(t)}}$又由其能量与所有可能状态向量的能量确定：

5.5 其他常见神经网络

Boltzmann 机 [Ackley et al.， 1985]

Boltzmann 机训练

- 将每个训练样本视为一个状态向量，使其出现的概率尽可能大
- 标准的 Boltzmann 机是一个全连接图，训练网络的复杂度很高，这使其难以用于解决现实任务
- 现实中常用受限 Boltzmann 机，简称RBM. RBM 仅保留显层与隐层之间的连接，从而将Boltzmann机结构有完全图简化为二部图

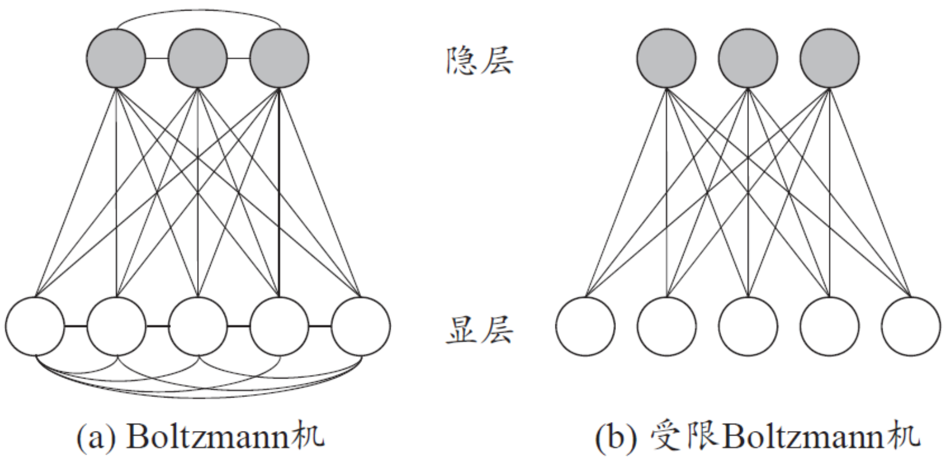

图 5.14 Boltzmann 机与受限 Boltzmann 机

5.5 其他常见神经网络

受限 Boltzmann 机 [Ackley et al., 1985]

- 受限 Boltzmann 机常用“对比散度”(简称:CD)算法 [Hinton, 2010] 来进行训练
  - 假定网络中有 d 个显层神经元 q 个隐层神经元，令 $\boldsymbol{v}$ 和 $\boldsymbol{h}$ 分别是显层与隐层的状态向量，由于同一层内不存在连接，有

$$P(\boldsymbol{v}|\boldsymbol{h}) = -\prod_{i=1}^{d} P(v_i|\boldsymbol{h}),$$

$$P(\boldsymbol{h}|\boldsymbol{v}) = -\prod_{i=1}^{q} P(h_i|\boldsymbol{v}),$$

  - CD算法对每个训练样本 $\boldsymbol{v}$ 先计算出隐层神经元状态的概率分布，然后根据这个概率分布采样得到 $\boldsymbol{h}$；类似的方法从 $\boldsymbol{h}$ 中产生 $\boldsymbol{v}'$，再从 $\boldsymbol{v}'$ 中产生 $\boldsymbol{h}'$；连接权重的更新公式为：

$$\triangle w = \boldsymbol{v}\boldsymbol{h}^T - \boldsymbol{v}'\boldsymbol{h}'^T$$

第五章 神经网络

主要内容

- 5.1 神经元模型
- 5.2 感知机与多层网络
- 5.3 误差逆传播算法
- 5.4 全局最小与局部最小
- 5.5 其他常见神经网络
- 5.6 深度学习

5.6 深度学习

深度学习模型

- 典型的深度学习模型就是很深层的神经网络.

模型复杂度

- 增加隐层神经元的数目（模型宽度）
- 增加隐层数目（模型深度）
- 从增加模型复杂度的角度看，增加隐层的数目比增加隐层神经元的数目更有效．这是因为增加隐层数不仅增加额拥有激活函数的神经元数目，还增加了激活函数嵌套的层数.

复杂模型难点

多隐层网络难以直接用经典算法（例如标准BP算法）进行训练，因为误差在多隐层内逆传播时，往往会”发散”而不能收敛到稳定状态.

5.6 深度学习

复杂模型训练方法

- 预训练+微调
  - 预训练:监督逐层训练是多隐层网络训练的有效手段, 每次训练一层隐层结点, 训练时将上一层隐层结点的输出作为输入, 而本层隐结点的输出作为下一层隐结点的输入, 这称为"预训练".
  - 微调: 在预训练全部完成后, 再对整个网络进行微调训练. 微调一般使用BP算法.
- 例子: 深度信念网络 [Hintonet al. , 2006]
  - 结构: 每一层都是一个受限 Boltzmann 机
  - 训练方法: 无监督预训练+BP 微调
- 分析

预训练+微调 的做法可以视为将大量参数分组, 对每组先找到局部看起来比较好的设置, 然后再基于这些局部较优的结果联合起来进行全局寻优.

5.6 深度学习

复杂模型训练方法

权共享

- 一组神经元使用相同的连接权值.
- 权共享策略在卷积神经网络(CNN)[LeCun and Bengio, 1995; LeCun et al., 1998]中发挥了重要作用.

卷积神经网络

结构：CNN复合多个卷积层和采样层对输入信号进行加工, 然后在连接层实现与输出目标之间的映射.

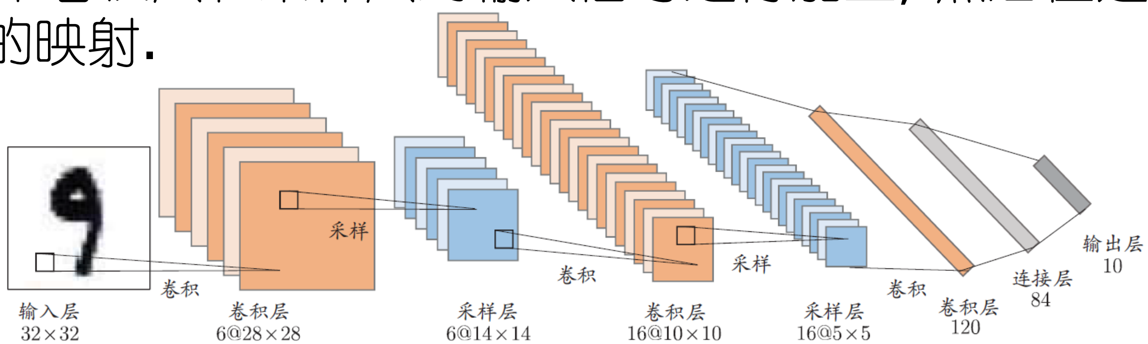

图 5.15 卷积神经网络用于手写数字识别 [LeCun et al., 1998]

5.6 深度学习

卷积神经网络

- 卷基层：每个卷基层包含多个特征映射，每个特征映射是一个由多个神经元构成的“平面”，通过一种卷积滤波器提取的一种特征
- 采样层：亦称“汇合层”，其作用是基于局部相关性原理进行亚采样，从而在减少数据量的同时保留有用信息
- 连接层：每个神经元被全连接到上一层每个神经元，本质就是传统的神经网络，其目的是通过连接层和输出层的连接完成识别任务

卷积神经网络激活函数

在CNN中通常将 sigmoid 激活函数替换为修正的线性函数

$$f(x) = \max(0, x)$$

卷积神经网络训练

CNN 可以用BP进行训练，但在训练中，无论是卷积层还是采样层，每一组神经元都是用相同的连接权，从而大幅减少了需要训练的参数数目

5.6 深度学习

理解深度学习

- “特征工程” VS “特征学习”或者 “表示学习”
- 特征工程由人类专家根据现实任务来设计，特征提取与识别是单独的两个阶段；

手工设计特征 → 分类识别

- 特征学习通过深度学习技术自动产生有益于分类的特征，是一个端到端的学习框架.

学习生成特征 → 分类识别

5.6 深度学习

深度学习常用软件包

- CAFFE

  The Berkeley Vision and Learning Center (BVLC)

  http://caffe.berkeleyvision.org/

- MatConvNet

  The Oxford Visual Geometry Group (VGG)

  http://www.vlfeat.org/matconvnet/

- Torch

  http://torch.ch/

神经网络基础教材

http://hagan.okstate.edu/

5.6 深度学习

□ 深度学习常用软件包

- TensorFlow

  Google

  https://tensorflow.google.cn/

- PyTorch

  Facebook

  http://www.vlfeat.org/matconvnet/

- Keras

  http://keras.io/

playground.tensorflow.org

https://www-cs-faculty.stanford.edu/people/karpathy/convnetjs/started.html

5.7 阅读材料

主流学术期刊

- Neural Computation
- Neural Networks
- IEEE Transactions on Neural Networks and Learning Systems

国际会议

- 国际神经信息处理系统会议（NIPS）
- 国际神经网络联合会议（IJCNN）

区域性国际会议

- 欧洲神经网络会议（ICANN）
- 亚太神经网络会议（ICONIP）

谢谢大家!